

Bitácora — tfm-churn-ecommerce

Predicción de churn en e-commerce · UCI Online Retail II

Actualización: 30 de septiembre de 2026

Fase actual: calibración cerrada; modelo final seleccionado: Random Forest calibrado con Platt sobre validación.

Próximo frente: interpretabilidad mediante SHAP.

1. Resumen ejecutivo

- Pipeline validado: limpieza de datos, creación de características RFM, dataset multi-snapshot mensual y separación temporal train/valid/test.
- Se compararon Logistic Regression, Random Forest y XGBoost bajo criterios de estabilidad, calibración, discriminación e interpretabilidad.
- La calibración Platt con validación cruzada interna en train no corrige la deriva temporal. La solución adoptada es calibrar fuera de tiempo: modelo base congelado y calibrador ajustado sobre valid.
- **Modelo final:** Random Forest calibrado con Platt. Umbral operativo 0.599, elegido en valid con objetivo de recall ≥ 0.8 .
- En test, el modelo final obtiene precision 0.7495, recall 0.8146 y F1 0.7807.
- XGBoost se descarta por peor calibración residual, menor estabilidad de umbrales y colapso bajo reentrenamiento por folds.

2. Decisiones registradas

ID	Decisión	Justificación
D1	Calibración fuera de tiempo mediante <code>calibrate_predit</code> , con modelo base congelado y calibrador Platt ajustado en valid.	La prevalencia deriva entre train, valid y test: 0.4934 → 0.6451 → 0.5870. Valid contiene los datos más recientes disponibles antes de test.
D2	Umbral operativo elegido en valid con objetivo recall ≥ 0.8 ; se reporta también 0.5 como referencia.	Con probabilidades calibradas, 0.5 representa el punto natural de “más probable que no”.
D3	Random Forest como modelo final; Logistic como baseline interpretable; XGBoost descartado.	RF gana Brier, ROC-AUC y PR-AUC en test y es el único que mantiene recall superior a 0.8.
D4	Omitir XGBoost de la tabla principal de Platt-CV-en-train e incluir una nota explicativa.	La CV sin barajar sobre train ordenado temporalmente produce folds contiguos y predicciones OOF invertidas.
D5	Usar sigmoid/Platt en lugar de isotonic.	Isotonic no ofrece una mejora suficiente frente a la mayor complejidad y varianza potencial.

3. Bitácora de sesiones

Sesión 1 — Transferencia y diagnóstico inicial

- Se transfirió el proyecto desde otro LLM mediante un ZIP del repositorio.
- Se analizó el pipeline: limpieza, variables RFM, snapshots mensuales y split temporal.
- Los primeros resultados mostraron peor calibración en Random Forest y XGBoost que en Logistic.

Sesión 2 — Implementación de la recalibración

- Se implementó `build_calibrated_pipeline` con sigmoid y CV interna en `src/evaluation/calibration.py`.
- Se actualizó `scripts/evaluate_thresholds.py` para recalibración y análisis de umbrales.
- Se aclaró que debían actualizarse archivos existentes y no crear archivos `*_updated.py`.
- Se añadió el test `test_calibrate_predit_preserves_ranking`.
- Se resolvió el error `NameError: calibrate_predit is not defined` añadiendo la función y su import.
- Resultado: **7/7 tests superados**.

Sesión 3 — Ejecución completa y decisión de modelo

- Se ejecutó la evaluación completa con análisis de calibración, umbrales y sensibilidad isotónica.
- Platt-CV-en-train no transfirió adecuadamente a los periodos posteriores.
- Se detectó la anomalía de XGBoost: ROC-AUC 0.2676 en valid y 0.3207 en test dentro de la sección de referencia.
- El diagnóstico `scripts/diagnostico_xgboost.py` obtuvo AUC por fold `[0.5747, 0.4526, 0.3810, 0.3709, 0.4320]` y AUC OOF agrupado 0.4385.
- Se verificaron `src/evaluation/calibration.py` y `src/models/xgboost_model.py`; ambos quedaron correctamente integrados.
- Los controles confirmaron que la calibración conserva el ranking: ROC-AUC y PR-AUC no cambian.

4. Métricas clave en test

Resultados después de calibrar con Platt sobre validación, manteniendo el modelo base congelado:

Modelo	Brier	ECE	ROC-AUC	PR-AUC	Umbral recall $\geq$ 0.8	Precision / Recall / F1
Logistic	0.1886	0.0385	0.7702	0.7852	0.643	0.7549 / 0.7653 / 0.7601
Random Forest	0.1863	0.0563	0.7789	0.8104	0.599	0.7495 / 0.8146 / 0.7807
XGBoost	0.1990	0.1007	0.7679	0.8018	0.541	0.7119 / 0.8833 / 0.7884

- RF es el único que cumple el objetivo recall $\geq$ 0.8 en test.
- RF con umbral 0.5 obtiene precision 0.7219, recall 0.8824 y F1 0.7941 en test.

- Sensibilidad isotonic en test: Logistic Brier/ECE 0.1881/0.0298; RF 0.1856/0.0566; XGBoost 0.1980/0.0963.
- Prevalencias: train 0.4934, valid 0.6451 y test 0.5870.
- La deriva explica el ECE residual en test: el calibrador se ajustó con prevalencia 0.6451 y se evaluó en un periodo con prevalencia 0.5870.

5. Diagnóstico de XGBoost

`build_multi_snapshot_dataset` concatena snapshots en orden cronológico. Por ello, train queda ordenado por `cutoff_date`. Cuando se usa `cv=5` entero, sklearn aplica `StratifiedKFold` sin barajar. En consecuencia, los folds son bloques temporales contiguos.

Cada modelo de fold se entrena con una distribución temporal distinta de aquella sobre la que predice. La deriva de prevalencia hace que las escalas aprendidas sean incompatibles y que las predicciones OOF agrupadas resulten parcialmente invertidas.

La CV interna de la sección 2 debe interpretarse como una CV fuera de tiempo encubierta. La sección 3 —modelo base completo congelado y calibración sobre valid— es la estrategia adoptada.

La referencia de Platt con CV interna en train se muestra solo para Logistic y Random Forest. En XGBoost, la CV interna sobre train ordenado temporalmente produce un AUC out-of-fold de 0.44: los folds sin barajar actúan como bloques temporales contiguos y, ante la deriva de prevalencia del panel multi-snapshot, las predicciones agrupadas salen invertidas. Esta sensibilidad motiva recalibrar fuera de tiempo con el modelo base congelado y ajuste sobre valid.

6. Artefactos y comandos

Archivo	Estado o función
<code>src/evaluation/calibration.py</code>	Incluye <code>build_calibrated_pipeline</code> y <code>calibrate_predit</code> , con compatibilidad mediante <code>FrozenEstimator</code> o <code>cv="predit"</code> .
<code>scripts/evaluate_thresholds.py</code>	Evaluación de prevalencias, calibración, umbrales, isotonic y resumen final en test.
<code>tests/test_calibration.py</code>	Incluye el test de preservación del ranking. Todos los tests pasan.
<code>scripts/diagnostico_xgboost.py</code>	Diagnóstico de la anomalía de XGBoost y evidencia del efecto temporal de los folds.

Comandos de ejecución:

```
uv run pytest tests/test_calibration.py tests/test_threshold.py -v
uv run python scripts/evaluate_thresholds.py
uv run python scripts/diagnostico_xgboost.py
```

Gráficos esperados en `reports/`: `calibration_raw_{valid,test}.png`, `calibration_sigmoid_traincv_{valid,test}.png` y `calibration_platt_{valid,test}.png`.

7. Pendientes y próximos pasos

1. Realizar el análisis de interpretabilidad SHAP sobre el Random Forest calibrado.
2. Ejecutar, si se desea, el control de CV con `shuffle=True` y el control in-sample de XGBoost.
3. Decidir el tratamiento del segmento wholesale: exclusión o incorporación de una interacción B2B.
4. Completar la documentación final del TFM: metodología, calibración, selección de modelo y tabla de resultados.
5. Valorar opcionalmente `ensemble=False` en `build_calibrated_pipeline` para comparabilidad estricta entre secciones.

8. Convenciones metodológicas

- Separación temporal estricta train/valid/test.
- No ajustar calibradores ni umbrales utilizando test.
- Calibrar en valid solo con el modelo base congelado.
- Ejecutar scripts y tests mediante `uv`.
- Priorizar estabilidad, calibración, discriminación e interpretabilidad.
- Mantener la estructura y las convenciones de nombres del repositorio.

Documento de seguimiento del proyecto. Las métricas y decisiones reflejan la última ejecución compartida durante la sesión.