

TFM — Predicción de churn en e-commerce

UCI Online Retail II

Documentación final y bitácora de cierre

Modelo final: Random Forest calibrado con Platt en valid

Umbral operativo: 0.599

Fecha de cierre: 1 de octubre de 2026

Documentación final del TFM

Proyecto: TFM — Predicción de churn en e-commerce (UCI Online Retail II).

Modelo final: Random Forest + Platt ajustado en valid con el modelo base congelado.

Documento preparado con las cifras de las ejecuciones de cierre de `control_cv_shuffle.py` y `analisis_wholesale.py`. Los apéndices A y B contienen los controles técnicos y el análisis por segmento.

1. Interpretabilidad del modelo final

1.1 Método

Para explicar el modelo final se aplica SHAP mediante `TreeExplainer` sobre el Random Forest base. SHAP asigna a cada variable su contribución marginal a cada predicción con garantías de consistencia y aditividad. El calibrador Platt transforma la probabilidad mediante un remapeo monótono, sin alterar el ranking de clientes; por ello, las explicaciones del modelo base se trasladan al modelo calibrado que produce las decisiones.

Sobre una muestra de 2.000 clientes de test, el error máximo de la descomposición aditiva, $\max | \text{base} + \sum \text{SHAP} - p_{\text{RF}} |$, fue **0.000000**.

Las explicaciones locales se seleccionaron por probabilidad del modelo, no por la etiqueta real. La etiqueta solo se mostró como contexto posterior.

1.2 Importancia global

Variable	media SHAP	% total	Dirección media	Lectura
monetary	0.0751	24.7%	hacia no churn	Mayor gasto acumulado reduce el riesgo.
frequency	0.0749	24.6%	hacia no churn	Mayor frecuencia reduce el riesgo.
recency	0.0602	19.8%	hacia churn	Más días desde la última compra aumentan el riesgo.
n_products	0.0309	10.1%	hacia no churn	Variedad de producto como señal de engagement.
month_cos	0.0250	8.2%	hacia no churn	Componente estacional.
avg_days_between_purchases	0.0197	6.5%	hacia churn	Contribución media positiva.
month_sin	0.0149	4.9%	hacia churn	Componente estacional.
is_post_holiday	0.0038	1.2%	hacia no churn	Efecto marginal.
n_countries	0.0000	0.0%	—	Variable prácticamente constante.

El trío RFM concentra el **69.0%** de la atribución total. recency empuja hacia churn, mientras que monetary y frequency empujan mayoritariamente hacia no churn. `n_countries` tiene media `| SHAP|` igual a cero y el bosque nunca divide por ella.

1.3 Explicaciones locales

Riesgo alto: Customer ID 15233, cutoff 2011-06-01, recency 209, frequency 1 y monetary 59.40. La probabilidad cruda fue 0.7837 y la calibrada 0.9563, por encima de 0.599: cliente prioritario. La etiqueta real, observada a posteriori, fue churn = 1.

Riesgo bajo: Customer ID 13089, cutoff 2011-05-01, recency 3, frequency 145 y monetary 81.385.17. La probabilidad cruda fue 0.0451 y la calibrada 0.1393: no prioritario.

El desplazamiento de Platt hacia arriba en la zona baja es coherente con la corrección de deriva: el modelo base se entrenó con prevalencia 0.4934 y el calibrador se ajustó sobre valid, con prevalencia 0.6451.

2. Resumen metodológico

2.1 Datos y preparación

Sobre UCI Online Retail II (2009–2011) se conservan ventas con Customer ID válido y se excluyen cancelaciones. Para cada corte mensual se construyen variables con ventana retrospectiva de 365 días: RFM, mezcla de producto y estacionalidad. La etiqueta es churn a 90 días.

2.2 Split temporal y deriva

La división es estrictamente temporal. Prevalencias: train 0.4934 ($n=32537$), valid 0.6451 ($n=17076$) y test 0.5870 ($n=21668$). La deriva de prevalencia motiva la calibración fuera de tiempo.

2.3 Modelos y protocolo

Se comparan Dummy, Regresión Logística, Random Forest y XGBoost bajo preprocesamiento común, imputación por mediana y tratamiento del desbalance. La selección prioriza estabilidad, calibración, discriminación e interpretabilidad.

2.4 Calibración fuera de tiempo

La calibración Platt con CV interna en train no transfiere adecuadamente al bloque siguiente. La decisión adoptada es congelar el modelo base y ajustar el calibrador Platt sobre valid, el bloque más reciente previo a test. El umbral operativo se elige en valid con objetivo recall ≥ 0.80 , resultando 0.599.

2.5 Evaluación

Se emplean Brier, ECE, ROC-AUC, PR-AUC y matrices de confusión en valid y test. También se controla la monotonía: AUC idénticos antes y después de calibrar, con umbrales remapeados equivalentes.

3. Tabla final de resultados — test

Modelo	Brier	ECE	ROC-AUC	PR-AUC	Umbral valid	Precision	Recall	F1
logistic	0.1886	0.0385	0.7702	0.7852	0.643	0.7549	0.7653	0.7601
random_forest	0.1863	0.0563	0.7789	0.8104	0.599	0.7495	0.8146	0.7807
xgboost	0.1990	0.1007	0.7679	0.8018	0.541	0.7119	0.8833	0.7884

Random Forest es el modelo final: obtiene el mejor Brier, ROC-AUC y PR-AUC entre los candidatos relevantes y cumple el objetivo de recall en test. XGBoost presenta peor calibración residual y sensibilidad estructural al reentrenamiento, documentada en el Apéndice A.

Con umbral 0.5, Random Forest alcanza en test precision 0.7219, recall 0.8824 y F1 0.7941.

4. Decisión D6 — segmento wholesale

Se mantiene el modelo entrenado sobre la población completa y se documenta wholesale como heterogeneidad conocida. La definición es $\text{monetary} \geq p_{90} \text{ de train} = 2736.07$, sin fuga de información.

El modelo ordena bien dentro de wholesale: ROC-AUC 0.7945 en test, superior al 0.7035 del resto. La limitación está en la política de umbral global: con 0.599, el recall de wholesale cae a 0.3333 en test, frente a 0.8624 en el resto. Quedan como trabajo futuro los umbrales por segmento, features de interacción B2B o un modelo jerárquico.

5. Limitaciones y trabajo futuro

- Wholesale: buen ranking, pero recall bajo con el umbral global.
- `n_countries`: variable prácticamente constante y sin importancia SHAP.
- ECE residual en test: deriva temporal; se recomienda recalibrar periódicamente con datos recientes.
- Etiqueta y horizonte: churn definido a 90 días; otros horizontes pueden cambiar el trade-off.
- Generalización externa: un solo retailer, con mayoría de clientes del Reino Unido.
- XGBoost: descartado por sensibilidad a folds temporales y peor calibración residual.

Apéndice A — Control CV de XGBoost

Control	ROC-AUC
In-sample, train completo	0.7948
CV sin barajar — folds	0.5747 / 0.4526 / 0.3810 / 0.3709 / 0.4320
CV sin barajar — OOF agrupado	0.4385
CV barajada — folds	0.7663 / 0.7859 / 0.7731 / 0.7751 / 0.7737
CV barajada — OOF agrupado	0.7747
Referencia out-of-time, valid	0.7697

El in-sample alto demuestra que el modelo aprende. La CV en bloques temporales reproduce la anomalía; al mezclar meses, el OOF se normaliza y queda próximo a valid. El confusor era la estructura temporal de los folds, no el modelo ni la calibración.

Apéndice B — Robustez por segmento

Control `n_countries`: 1 país = 99.8513%; 2 países = 0.1487%.

Split	Segmento	n (%)	Prev.	Brier	ROC-AUC	PR-AUC	Precision	Recall	F1
Valid	resto	14068 (82.4%)	0.7268	0.1781	0.6986	0.8442	0.7976	0.8353	0.8160
Valid	wholesale	3008 (17.6%)	0.2626	0.1636	0.7762	0.5846	0.6395	0.3481	0.4508
Test	resto	17040 (78.6%)	0.6790	0.1952	0.7035	0.8220	0.7531	0.8624	0.8040
Test	wholesale	4628 (21.4%)	0.2483	0.1534	0.7945	0.5691	0.6672	0.3333	0.4446

El análisis no reentrena ni modifica el modelo final. El menor Brier del segmento refleja su baja prevalencia; el menor PR-AUC debe interpretarse en esa escala de prevalencia.

Apéndice C — Reproducibilidad

```
uv run pytest
uv run python scripts/evaluate_thresholds.py
uv run python scripts/analyze_shap.py
uv run python scripts/control_cv_shuffle.py
uv run python scripts/analisis_wholesale.py
```

Bitácora de cierre

Proyecto: tfm-churn-ecommerce

Fase: proyecto completo y cerrado — sesión 5.

Resumen ejecutivo

- Pipeline validado: limpieza → features RFM → dataset multi-snapshot mensual → split temporal train/valid/test.
- Modelo final: Random Forest calibrado con Platt sobre valid y umbral 0.599.
- En test: precision 0.7495, recall 0.8146 y F1 0.7807.
- XGBoost descartado: OOF 0.4385 con CV temporal sin barajar, frente a 0.7747 con CV barajada.
- SHAP: RFM concentra aproximadamente el 69% de la atribución total; `n_countries` no discrimina.

Decisiones registradas

Decisión	Contenido
D1	Calibración fuera de tiempo: modelo base congelado y Platt ajustado en valid.
D2	Umbral operativo elegido en valid con recall objetivo ≥ 0.8 ; se reporta también 0.5.
D3	Random Forest como modelo final; Logistic como baseline; XGBoost descartado.
D4	La anomalía de XGBoost se documenta como efecto de folds temporales sobre datos ordenados.
D5	Platt, frente a isotonic, por menor complejidad y resultados equivalentes.
D6	Mantener la población completa y documentar wholesale como limitación operativa.

Sesiones completadas

Sesiones 1–3 — transferencia, calibración y diagnóstico

Se revisó el pipeline de limpieza, features, snapshots y split temporal. Se implementó la calibración y se añadió el test de preservación del ranking. La incidencia `NameError: calibrate_predit is not defined` quedó resuelta y la suite alcanzó 7/7 tests en verde. Se identificó que la anomalía de XGBoost procedía del reentrenamiento con folds temporales sobre datos ordenados.

Sesión 4 — interpretabilidad SHAP

Se creó `scripts/analyze_shap.py`. Se verificaron las prevalencias y el umbral 0.599. La descomposición aditiva SHAP reprodujo exactamente las probabilidades del bosque. Se documentaron las importancias globales, las direcciones medias y los casos de riesgo alto y bajo.

Sesión 5 — cierre técnico y documental

Se ejecutaron `control_cv_shuffle.py` y `analisis_wholesale.py`. Se aplicó el cableado del parámetro `ensemble=True` en la calibración, manteniendo los resultados congelados. Se validó D6 y se completaron los apéndices A y B.

Estado final

Proyecto cerrado. No quedan pendientes técnicos o documentales dentro del alcance actual. Los siguientes frentes, fuera de alcance, son integrar la documentación en la memoria oficial y preparar las diapositivas de defensa.

Artefactos y convenciones

- `src/evaluation/calibration.py`: calibración y recalibración `prefit`.
- `scripts/evaluate_thresholds.py`: evaluación y umbrales.
- `scripts/diagnostico_xgboost.py` y `scripts/control_cv_shuffle.py`: controles de XGBoost.
- `scripts/analyze_shap.py`: interpretabilidad del modelo final.
- `scripts/analisis_wholesale.py`: robustez por segmento.
- Separación temporal estricta, ejecución con `uv` y `test` sin utilizarse para ajustar decisiones.